

Ejercicio 1: Explorando Modelos Generativos de Imágenes

Duración estimada: 30 minutos | *Tipo:* Exploración | *Modalidad:* Individual | *Dificultad:* Básica
| *Prerrequisitos:* Ninguno

Contexto

Antes de profundizar en la teoría, es útil experimentar con modelos generativos para desarrollar intuición sobre sus capacidades y limitaciones.

Objetivo de Aprendizaje

Al completar este ejercicio, el estudiante será capaz de:

- Experimentar con diferentes modelos de generación de imágenes
 - Identificar diferencias cualitativas entre técnicas
 - Reconocer limitaciones prácticas de cada enfoque
-

Parte A: Generación de Rostros con GANs (10 minutos)

1. Visita la siguiente página web: **thispersondoesnotexist.com**
2. Recarga la página **entre 5 y 10 veces**.
3. Observa y anota los siguientes aspectos:
 - ¿Los rostros parecen reales?
 - En general sí, los rostros transmiten una apariencia bastante convincente a primera vista, especialmente en la zona central de la cara. Sin embargo, al observar con más detalle se aprecian imperfecciones que delatan que son imágenes generadas artificialmente. La mayoría engañaría en una foto de perfil pequeña, pero no resisten un análisis cercano.
 - ¿Detectas algún artefacto o error?
 - Sí. Los errores más frecuentes aparecen en zonas de detalle fino como los ojos, donde a veces la pupila o el iris presentan formas irregulares, el pelo, que en ocasiones se funde con el fondo de manera poco natural o muestra mechones imposibles, y los dientes, que tienden a aparecer desproporcionados, fusionados o con formas extrañas. Ocasionalmente aparece algún rostro con múltiples errores simultáneos, lo que hace la imagen claramente artificial.
 - ¿Qué partes de la imagen presentan más problemas? (*orejas, dientes, fondos, accesorios*)
 - *Las zonas más problemáticas son los elementos asimétricos o de alta frecuencia de detalle: el pelo y su contorno con el fondo, los dientes cuando la boca está abierta, los ojos en cuanto a simetría y reflejo de luz, y los accesorios como pendientes o gafas, que a menudo aparecen deformados o solo en uno de los lados. Los fondos también suelen presentar borrosidad o texturas inconsistentes. Esto es característico de las GANs, que dominan bien las formas globales pero pierden precisión en los detalles locales.*

Parte B: Generación con Modelos de Difusión (15 minutos)

1. Accede a uno de estos playgrounds gratuitos (todos son gratuitos, elige el que prefieras):
 - **Stable Diffusion Demo**
 - **Playground AI** (*requiere cuenta gratuita*)
 - **Leonardo AI** (*requiere cuenta gratuita*)
2. Genera imágenes con los siguientes prompts, uno por uno:
 - "A cat sitting on a laptop, photorealistic"
 - "A futuristic city at sunset, cyberpunk style"
 - "A medieval knight riding a horse, oil painting"
3. Para cada imagen generada, anota:
 - **Tiempo de generación** aproximado
 - **Calidad percibida** del 1 al 10
 - **Adherencia al prompt** del 1 al 10 (*es decir, ¿la imagen representa bien lo que pediste?*)




Imagen 1 — "A cat sitting on a laptop, photorealistic"

- **Tiempo de generación:** ~20 segundos
- **Calidad percibida:** 7/10 — El gato está bien generado, con pelaje detallado y ojos realistas. Sin embargo, la posición no es exactamente la del prompt: el gato aparece *delante* del portátil, no *encima*.
- **Adherencia al prompt:** 6/10 — Capta el concepto general pero no interpreta correctamente la preposición "sitting on".

Imagen 2 — "A futuristic city at sunset, cyberpunk style"

- **Tiempo de generación:** ~10 segundos
- **Calidad percibida:** 8/10 — Muy buena composición, con luces de neón, rascacielos y un atardecer dramático muy característico del estilo cyberpunk.
- **Adherencia al prompt:** 9/10 — Representa fielmente todos los elementos pedidos.

Imagen 3 — "A medieval knight riding a horse, oil painting"

- **Tiempo de generación:** ~10 segundos
 - **Calidad percibida:** 9/10 — Resultado muy convincente, con textura de pinceladas visible y una composición clásica que imita bien una pintura al óleo real.
 - **Adherencia al prompt:** 9/10 — Caballero, caballo y estilo pictórico perfectamente representados.
-

Parte C: Comparativa entre GANs y Modelos de Difusión (5 minutos)

Calidad

- **GANs:** Alta en el centro del rostro, pero irregular en los detalles finos como orejas, dientes y accesorios.
- **Difusión:** Alta de forma más consistente en toda la imagen, especialmente en escenas y estilos artísticos.

Velocidad

- **GANs:** Prácticamente instantánea, la imagen aparece al instante al recargar la página.
- **Difusión:** Más lenta, entre 10 y 35 segundos según la complejidad del prompt.

Control sobre el resultado

- **GANs:** Muy limitado, simplemente genera una imagen aleatoria sin posibilidad de dirigir el contenido.
- **Difusión:** Muy alto, el prompt permite controlar el estilo, el contenido y la composición con bastante precisión.

Artefactos observados

- **GANs:** Errores frecuentes en zonas asimétricas, pelo, dientes y fondos. Ocasionalmente rostros con múltiples fallos simultáneos.
 - **Difusión:** Artefactos menores y menos frecuentes. El principal error observado fue una interpretación incorrecta del prompt en la imagen del gato.
-

Preguntas de Reflexión

1. ¿Qué modelo te pareció más impresionante y por qué?

Los modelos de difusión resultaron más impresionantes en general. La capacidad de generar imágenes muy variadas simplemente describiendo lo que quieres en texto es algo muy potente e intuitivo. Especialmente llamativa fue la tercera imagen, que imitó con gran fidelidad el estilo de una pintura al óleo real, algo que una GAN especializada en rostros no podría hacer.

2. ¿En qué casos usarías cada técnica?

Las GANs serían útiles en aplicaciones que necesiten velocidad y un tipo de contenido muy concreto y repetitivo, como generación de avatares, filtros en tiempo real o creación masiva de personajes similares. Los modelos de difusión, en cambio, serían la elección para proyectos creativos donde se necesite variedad, control sobre el estilo y calidad visual elevada, como ilustración, diseño gráfico o generación de contenido artístico.

3. ¿Qué limitaciones éticas observas en estas herramientas?

La principal limitación ética de las GANs como *thispersondoesnotexist.com* es la facilidad para crear identidades falsas convincentes, lo que facilita la desinformación, el fraude o la suplantación de identidad. En los modelos de difusión, el riesgo ético está en la generación de contenido engañoso, la reproducción no autorizada de estilos artísticos de autores reales y la posibilidad de crear imágenes falsas de personas o situaciones inexistentes con apariencia realista.

Ejercicio 2: Análisis de Arquitectura GAN

Duración estimada: 25 minutos | *Tipo:* Análisis | *Modalidad:* Parejas | *Dificultad:* Intermedia | *Prerequisitos:* Conceptos de redes neuronales

Contexto

Entender la dinámica adversarial de las GANs es fundamental para comprender por qué funcionan y cuáles son sus limitaciones.

Objetivo de Aprendizaje

- Explicar el flujo de información en una GAN
 - Identificar el objetivo de cada componente
 - Comprender la dinámica de entrenamiento
-

Parte A: Comprensión Básica

Responde las siguientes preguntas sobre el diagrama de la GAN:

1. **¿Cuál es el input del Generador? ¿Por qué se usa ruido aleatorio?**
 - El input del Generador es un vector de ruido aleatorio, habitualmente representado como z , que sigue una distribución normal estándar $N(0,1)$. Se usa ruido aleatorio porque permite que cada vez que se muestree un vector diferente se obtenga una imagen distinta, dotando al modelo de capacidad para generar contenido variado y no repetitivo. Sin ese componente aleatorio, el Generador siempre produciría la misma imagen.
2. **¿Cuál es el output del Discriminador? ¿Qué significa ese valor?**
 - El output del Discriminador es un valor numérico entre 0 y 1. Un valor cercano a **1** indica que el Discriminador considera que la imagen es *real*,

mientras que un valor cercano a **0** indica que la considera *falsa*. Es esencialmente una probabilidad de autenticidad.

3. ¿Por qué el Discriminador recibe tanto imágenes reales como falsas?

- Porque necesita aprender a distinguir entre ambas. Si solo viera imágenes reales no tendría referencia de qué es falso, y si solo viera falsas no sabría qué es real. Recibir ambas durante el entrenamiento es lo que le permite desarrollar criterio para clasificarlas correctamente.

Parte B: Dinámica de Entrenamiento

1. Durante el entrenamiento del Discriminador: ¿Qué gradientes recibe? ¿Hacia qué objetivo se mueve?

El Discriminador recibe gradientes que provienen del error cometido al clasificar imágenes reales como falsas y viceversa. Su objetivo es maximizar la precisión de clasificación, es decir, acercarse a dar **1** cuando recibe una imagen real y **0** cuando recibe una imagen generada por el Generador.

2. Durante el entrenamiento del Generador: ¿Qué gradientes recibe? ¿Cómo sabe si está mejorando? ¿Por qué el Discriminador se "congela" en esta fase?

El Generador recibe gradientes que provienen de la respuesta del Discriminador ante sus imágenes falsas. Sabe que está mejorando cuando el Discriminador empieza a asignar valores cercanos a **1** a sus imágenes, es decir, cuando logra engañarlo. El Discriminador se congela en esta fase porque si también se actualizara al mismo tiempo, los gradientes que llegarían al Generador serían inestables e inconsistentes, impidiendo un aprendizaje coherente.

Parte C: Problemas Comunes

1. Mode Collapse: Si el Generador produce siempre imágenes muy similares, ¿por qué podría ocurrir esto? ¿Cómo afecta al Discriminador?

El Mode Collapse ocurre cuando el Generador descubre que un tipo concreto de imagen engaña con éxito al Discriminador y se "especializa" en producir siempre variaciones de esa misma imagen, ignorando el resto de posibilidades. En lugar de aprender la distribución completa de los datos, toma el camino fácil. Esto afecta directamente al Discriminador porque deja de recibir diversidad de ejemplos falsos, lo que limita su capacidad de mejorar y rompe el equilibrio del entrenamiento. Como se ve en las diapositivas, el resultado son outputs de poca diversidad aunque individualmente puedan parecer correctos.

2. Equilibrio de Nash: ¿Qué pasa si el Discriminador es mucho mejor que el Generador al inicio?

Si el Discriminador es demasiado bueno desde el principio, detecta con facilidad y certeza todas las imágenes falsas del Generador. Esto provoca el problema conocido como

Vanishing Gradients: el error que llega al Generador es tan pequeño e insignificante que prácticamente no aprende nada, quedándose estancado. El punto ideal, como indica la dinámica de convergencia de las GANs, es que el Discriminador acierte aproximadamente el **50%** de las veces, es decir, que le resulte imposible distinguir entre real y falso.

Ejercicio 3: Espacio Latente en VAEs

Duración estimada: 30 minutos | *Tipo*: Programación/Exploración | *Modalidad*: Individual | *Dificultad*: Intermedia | *Prerequisitos*: Python básico, conceptos de VAE

Contexto

Una de las propiedades más útiles de los VAEs es su espacio latente estructurado, que permite interpolación suave entre ejemplos.

Objetivo de Aprendizaje

- Visualizar el espacio latente de un VAE
 - Experimentar con interpolación entre puntos
 - Comprender la relación entre espacio latente y datos generados
-

Parte A: Exploración del Espacio Latente (15 minutos)

Para esta parte necesitas acceder al **MNIST VAE Demo** online, donde verás un mapa 2D en el que cada punto corresponde a un dígito del 0 al 9.

Lo que tienes que hacer:

1. Mueve el cursor por distintas zonas del mapa
2. Observa qué dígito aparece en cada zona
3. Fíjate especialmente en las fronteras entre grupos de dígitos

¿Los dígitos similares están cerca en el espacio latente?

Sí, los dígitos visualmente similares tienden a agruparse en zonas próximas del espacio latente. Esto no es casualidad, sino una consecuencia directa de cómo el VAE organiza la información: aprende a colocar cerca aquellos dígitos que comparten características visuales, como la curvatura o el número de trazos. Por ejemplo, el 3 y el 8 suelen estar relativamente cerca porque ambos tienen curvas similares.

¿Hay zonas "vacías" sin significado?

Sí, en los extremos y esquinas del espacio latente pueden aparecer zonas de transición donde los dígitos generados son ambiguos o poco reconocibles. Esto ocurre porque el VAE fuerza al espacio latente a seguir una distribución continua, pero algunas combinaciones de valores no corresponden a ningún dígito bien definido del conjunto de entrenamiento.

¿Qué pasa en las fronteras entre clusters de dígitos?

En las fronteras los dígitos se van difuminando y transformando gradualmente de uno a otro. Esto es precisamente la propiedad clave de los VAEs: la **interpolación suave**. A diferencia de otros modelos, no hay un salto brusco entre un dígito y otro, sino una transición continua y coherente, lo que demuestra que el espacio latente está estructurado y tiene significado geométrico.

Parte B: Interpolación (10 minutos)

Selección de dos puntos: un "3" y un "8"

Tomando como referencia dos puntos del espacio latente que corresponden a un 3 y a un 8, la línea recta imaginaria que los une representa una interpolación lineal entre ambos dígitos.

¿Qué dígitos esperarías ver en los puntos intermedios?

En los puntos intermedios de esa línea se esperaría ver formas ambiguas que comparten características de ambos dígitos simultáneamente. Al principio, cerca del 3, aparecería un dígito que todavía se reconoce como 3 pero con las curvas inferiores empezando a cerrarse. En el punto medio la forma sería completamente ambigua, ni 3 ni 8 de forma clara. Al acercarse al 8, las curvas se irían cerrando hasta formar el bucle superior e inferior característico del 8.

¿Se cumple la hipótesis al mover el cursor?

Sí, esto es exactamente lo que ocurre al desplazar el cursor entre ambos puntos. La transición es suave y coherente en todo momento, sin saltos ni imágenes sin sentido. Esto demuestra que el espacio latente del VAE no es aleatorio, sino que tiene una **estructura geométrica con significado real**, donde la distancia entre dos puntos refleja la similitud visual entre los datos que representan.

Parte C: Código de Interpolación

```
python
```

```
import numpy as np
```

```
def interpolate_latent(z1, z2, steps=10):
```

```
    interpolated = []
```

```
    for i in range(steps):
```

```
        t = i / (steps - 1)
```

```
        z_interp = z1 * (1 - t) + z2 * t
```

```

        interpolated.append(z_interp)

    return interpolated

z1 = np.array([1.0, 0.5])
z2 = np.array([-0.5, -1.0])

puntos = interpolate_latent(z1, z2, steps=5)

for i, z in enumerate(puntos):

    print(f"Paso {i}: {z}")

```

Salida esperada del programa:

- Paso 0: [1.0, 0.5] — punto inicial, dígito "3"
- Paso 1: [0.625, 0.125] — transición, forma ambigua cercana al "3"
- Paso 2: [0.25, -0.25] — punto medio, forma completamente ambigua
- Paso 3: [-0.125, -0.625] — transición, forma ambigua cercana al "8"
- Paso 4: [-0.5, -1.0] — punto final, dígito "8"

Explicación del código:

La clave está en la fórmula $z1 * (1 - t) + z2 * t$. Cuando t vale 0 el resultado es completamente $z1$, cuando vale 1 es completamente $z2$, y para valores intermedios se obtiene una mezcla proporcional de ambos. Esto es lo que produce la transición suave característica de los VAEs.

Preguntas de Reflexión

1. ¿Por qué la interpolación en el espacio latente produce resultados coherentes?

Porque el VAE ha aprendido a organizar el espacio latente de forma continua y estructurada durante el entrenamiento. Gracias al término de divergencia KL de su función de pérdida, el modelo fuerza a que puntos cercanos en el espacio latente correspondan a datos similares. Esto significa que cualquier punto intermedio entre dos representaciones válidas también corresponde a algo con sentido, produciendo siempre una transición coherente y no imágenes aleatorias sin significado.

2. ¿Qué pasaría si intentaras interpolar en el espacio de píxeles directamente?

El resultado sería una mezcla visual sin sentido. Al interpolar directamente entre los píxeles de un 3 y un 8, se obtendría simplemente una imagen borrosa que es la media aritmética de ambos, sin estructura ni coherencia. No habría transformación gradual de uno a otro, sino una superposición opaca de los dos dígitos simultáneamente. Esto demuestra que el

espacio de píxeles no tiene estructura geométrica útil, al contrario que el espacio latente del VAE.

3. ¿Cómo podría usarse esta propiedad en aplicaciones reales?

Las aplicaciones son muy variadas. En edición de imágenes permite modificar atributos de forma continua y controlada, como envejecer un rostro gradualmente o cambiar la expresión facial. En animación permite generar transiciones suaves entre dos estados sin necesidad de dibujar los fotogramas intermedios manualmente. También se usa en diseño generativo para explorar variaciones de un producto o personaje, y en medicina para generar imágenes sintéticas intermedias entre distintos estados de una patología.

Ejercicio 4: Comparativa de Técnicas Generativas

Duración estimada: 35 minutos | *Tipo:* Análisis/Diseño | *Modalidad:* Grupal (3-4 personas) | *Dificultad:* Intermedia | *Prerequisitos:* Teoría de GANs, VAEs, Difusión

Contexto

En proyectos reales, la elección de la técnica generativa correcta depende de múltiples factores. Este ejercicio desarrolla el criterio para tomar estas decisiones.

Objetivo de Aprendizaje

- Evaluar tecnologías según criterios específicos
 - Justificar decisiones técnicas
 - Considerar trade-offs en diseño de sistemas
-

Caso 1: App de Filtros en Tiempo Real

Contexto: Startup desarrollando app móvil con filtros de belleza y envejecimiento.

Requisitos: procesamiento en tiempo real (<100ms por frame), funcionar en dispositivos móviles, calidad aceptable pero no perfecta.

Recomendación: GANs

Justificación:

La velocidad es el factor determinante en este caso. Las GANs generan imágenes en una sola pasada hacia adelante por la red, lo que las hace prácticamente instantáneas y perfectamente compatibles con el requisito de menos de 100ms por frame. Los modelos de difusión quedan descartados directamente porque necesitan entre 20 y 1000 pasos iterativos para generar una imagen, lo que los hace demasiado lentos para tiempo real. Los VAEs tampoco serían la mejor opción porque, aunque son rápidos, producen imágenes más borrosas y de menor calidad que las GANs.

Además, variantes como **CycleGAN** están específicamente diseñadas para transformación de estilos en imágenes, que es exactamente lo que necesita una app de filtros. Su huella computacional es lo suficientemente ligera como para ejecutarse en dispositivos móviles modernos, algo que confirman las propias diapositivas del curso al señalar las GANs como la opción recomendada cuando se requiere tiempo real o dispositivos móviles.

Caso 2: Generación de Arte para NFTs

Contexto: Plataforma de arte digital que genera colecciones de 10.000 imágenes únicas.

Requisitos: máxima calidad y diversidad, generación batch, control creativo mediante prompts de texto.

Recomendación: Modelos de Difusión

Justificación:

El tiempo no es crítico aquí ya que la generación es en batch, lo que elimina el único inconveniente de los modelos de difusión. A cambio se obtiene la máxima calidad posible, altísima diversidad entre imágenes y control total mediante prompts de texto, que es exactamente lo que necesita una plataforma creativa. Las GANs quedan descartadas porque tienen poco control sobre el resultado y tienden al mode collapse, lo que reduciría la diversidad de la colección. Como confirman las diapositivas, la difusión es la opción cuando la calidad absoluta es la prioridad y el tiempo no es un factor crítico.

Caso 3: Aumento de Datos Médicos

Contexto: Hospital que necesita generar imágenes sintéticas de rayos X para entrenar modelos de diagnóstico. Requisitos: realismo médico, control sobre atributos específicos, evitar casos imposibles.

Recomendación: VAEs

Justificación:

Este caso requiere un espacio latente estructurado y controlable, que es precisamente la fortaleza de los VAEs. Al mapear las imágenes a una distribución probabilística conocida, el VAE garantiza que las imágenes generadas sean variaciones realistas dentro del rango de lo posible médicamente, evitando generar casos imposibles o aberraciones que podrían contaminar el dataset de entrenamiento. Además, su espacio latente permite controlar atributos específicos como el tipo o la severidad de una patología moviéndose de forma controlada por dicho espacio. Las GANs quedan descartadas por su inestabilidad y riesgo de mode collapse, algo inaceptable en un entorno médico donde la fiabilidad es crítica.

Caso 4: Compresión de Imágenes para Archivo

Contexto: Biblioteca digital que necesita comprimir millones de imágenes históricas.

Requisitos: compresión extrema, reconstrucción de alta fidelidad, espacio latente navegable para búsqueda.

Recomendación: VAEs

Justificación:

Los VAEs son la única técnica de las tres que está diseñada explícitamente para comprimir y reconstruir datos a través de un espacio latente. El encoder comprime la imagen a una representación latente de dimensiones muy reducidas, logrando la compresión extrema requerida, y el decoder la reconstruye con alta fidelidad a partir de esa representación. Además, el espacio latente continuo y estructurado permite navegar y buscar imágenes por similitud visual, algo que ninguna otra técnica ofrece de forma tan natural. Las GANs y los modelos de difusión no tienen un mecanismo de compresión y reconstrucción equivalente, ya que están orientados a la generación y no al almacenamiento.

Matriz de Evaluación (puntuaciones del 1 al 5)

Velocidad de generación

- GANs: 5 — Una sola pasada, prácticamente instantánea
- VAEs: 4 — Muy rápidos, similar a las GANs
- Difusión: 2 — Lenta, requiere múltiples pasos iterativos

Calidad de imagen

- GANs: 4 — Alta, aunque con artefactos en detalles finos
- VAEs: 3 — Media, tendencia a imágenes borrosas
- Difusión: 5 — Estado del arte, la más alta de las tres

Estabilidad de entrenamiento

- GANs: 2 — Inestable, propenso a mode collapse y vanishing gradients
- VAEs: 4 — Estable gracias a su función de pérdida bien definida
- Difusión: 5 — Muy estable, proceso de entrenamiento predecible

Control sobre atributos

- GANs: 2 — Bajo, difícil dirigir el resultado con precisión
- VAEs: 4 — Estructurado, navegación controlada por el espacio latente
- Difusión: 5 — Muy alto mediante prompts de texto

Diversidad de outputs

- GANs: 2 — Limitada, riesgo de mode collapse
- VAEs: 4 — Alta gracias al espacio latente continuo
- Difusión: 5 — Muy alta, gran variedad entre generaciones

Recursos computacionales requeridos

- GANs: 4 — Ligeros en inferencia, viables en móvil
- VAEs: 4 — Ligeros y eficientes
- Difusión: 2 — Muy exigentes, requieren hardware potente

Facilidad de implementación

- GANs: 3 — Moderada, entrenamiento delicado y difícil de estabilizar
 - VAEs: 4 — Relativamente sencillos, arquitectura clara
 - Difusión: 3 — Moderada, conceptualmente más complejo
-

Ejercicio 5: Quiz de Conceptos

Duración estimada: 15 minutos | *Tipo:* Evaluación | *Modalidad:* Individual | *Dificultad:* Variada

Pregunta 1 (Básica) ¿Cuál es la principal diferencia entre un modelo discriminativo y uno generativo?

Respuesta correcta: b) Los modelos generativos aprenden la distribución conjunta $P(X,Y)$, es decir, *cómo se generan los datos*. Los discriminativos aprenden $P(Y|X)$, es decir, *a qué clase pertenece un dato dado*. Como muestra la diapositiva del curso, el discriminativo es el detective que clasifica, y el generativo es el creador que sintetiza.

Pregunta 2 (Intermedia) En una GAN, ¿qué ocurre si el Discriminador se vuelve demasiado bueno muy rápido?

Respuesta correcta: b) El Generador recibe gradientes muy pequeños y deja de aprender. Es el problema de *Vanishing Gradients* que ya trabajamos en el Ejercicio 2: si el Discriminador es perfecto, el feedback que recibe el Generador es tan débil que no puede mejorar.

Pregunta 3 (Intermedia) ¿Por qué los VAEs producen imágenes más borrosas que las GANs?

Respuesta correcta: b) La función de pérdida de reconstrucción del VAE calcula el error promediando sobre todas las posibles variaciones de una imagen, lo que hace que el modelo tienda a generar el "término medio" entre varias opciones posibles, perdiendo los detalles de alta frecuencia y produciendo resultados más borrosos.

Pregunta 4 (Avanzada) ¿Cuál es el propósito del término de divergencia KL en la función de pérdida del VAE?

Respuesta correcta: b) El término KL actúa como regularizador del espacio latente, forzando a que la distribución aprendida $q(z|x)$ se aproxime a una distribución normal estándar $N(0,1)$. Esto es lo que garantiza que el espacio latente esté estructurado, sea continuo y permita la interpolación suave que vimos en el Ejercicio 3.

Pregunta 5 (Avanzada) ¿Por qué los modelos de difusión son inherentemente más lentos en inferencia que las GANs?

Respuesta correcta: b) Porque necesitan ejecutar múltiples pasos de *denoising* iterativo para generar una imagen, típicamente entre 20 y 1000 pasos, partiendo de ruido puro hasta llegar a la imagen final. Las GANs en cambio generan la imagen en una única pasada hacia adelante por la red.

Ejercicio Extra: Investigación — DALL-E 3 (OpenAI, 2023)

Slide 1 — ¿Qué técnica usa?

DALL-E 3 es un modelo híbrido que combina dos arquitecturas. Por un lado usa un **modelo de difusión** para la generación de imágenes de alta calidad, y por otro integra un **LLM** (concretamente GPT-4) que reescribe y mejora automáticamente el prompt del usuario antes de enviárselo al modelo de difusión. Como muestra la diapositiva de hibridación del curso, es exactamente el sistema donde un LLM escribe el prompt perfecto para un modelo de difusión.

Slide 2 — ¿Qué lo diferencia de modelos anteriores?

La diferencia clave respecto a DALL-E 2 y otros modelos anteriores es su capacidad de seguir instrucciones de texto extremadamente precisas y complejas, incluyendo la generación de texto legible dentro de las imágenes, algo que históricamente era imposible para los modelos generativos. Además, al estar integrado con GPT-4, el usuario no necesita aprender a escribir prompts técnicos: el modelo los optimiza automáticamente.

Slide 3 — Principales aplicaciones

- Generación de ilustraciones y contenido visual para marketing y redes sociales
- Creación de prototipos visuales rápidos para diseñadores
- Generación de imágenes educativas y explicativas

- Herramienta creativa integrada en ChatGPT, accesible para cualquier usuario sin conocimientos técnicos
 - Generación de assets visuales para videojuegos e interfaces
-

Slide 4 — Limitaciones conocidas

- Rechaza generar imágenes de personas reales o contenido que pueda inducir a confusión con fotografías reales, lo que limita ciertos usos creativos
 - Aunque ha mejorado mucho, todavía comete errores en anatomía humana, especialmente en manos
 - No permite control preciso sobre la composición o la posición exacta de los elementos, ya que el proceso de difusión es probabilístico
 - Cada generación consume créditos, lo que limita el uso intensivo en versiones gratuitas
-

Slide 5 — Disponibilidad

DALL-E 3 está disponible públicamente de dos formas. La primera a través de **ChatGPT Plus**, donde cualquier usuario con suscripción de pago puede generar imágenes directamente desde la conversación. La segunda a través de la **API de OpenAI**, orientada a desarrolladores que quieran integrarlo en sus propias aplicaciones, bajo un modelo de pago por uso. No es open source, el modelo y sus pesos son propiedad de OpenAI y no están disponibles para descarga o uso local.

Fuentes recomendadas para citar:

- openai.com/dall-e-3
- Betker et al. (2023) — *Improving Image Generation with Better Captions* (paper oficial de OpenAI)
- blog.openai.com

Diego Martin Perez / Practica: Fundamentos de IA Generativa : realizado el 05/03/2026

Tutor : Ricardo Palacios